

➤ Task A: Reduce Overfitting

若使用原本的 model(都使用 30 個 epoch)最後的結果會如下圖，會出現 overfitting 的狀況，training 的 accuracy 很高(100%左右)但 validation 的 accuracy 就低很多

Epoch 30




圖 1, 原本 model 的 accuracy 和 loss

```
import torch.nn as nn
import torch.nn.functional as F

class ConvModel(nn.Module):
    def __init__(self):
        super().__init__()

        # 1 channel, and using 3x3 kernels for simplicity. 256*256
        self.conv1 = nn.Conv2d(1, 32, kernel_size=3, stride=1, padding='same')
        self.pool1 = nn.MaxPool2d(kernel_size=2, stride=2) # 128*128

        self.conv2 = nn.Conv2d(32, 32, kernel_size=3, stride=1, padding='same') # 128*128
        self.pool2 = nn.MaxPool2d(kernel_size=2, stride=2) # 64*64

        self.conv3 = nn.Conv2d(32, 32, kernel_size=3, stride=1, padding='same') # 64*64
        self.pool3 = nn.MaxPool2d(kernel_size=2, stride=2) # 32*32

        flattened_dim = 32 * 32 * 32 #channel數是32

        self.fc1 = nn.Linear(flattened_dim, 32)
        self.fc2 = nn.Linear(32, 1)
        # self.dropout = nn.Dropout(0.6)

    def forward(self, x):
        x = F.relu(self.conv1(x))
        x = self.pool1(x)

        x = F.relu(self.conv2(x))
        x = self.pool2(x)

        x = F.relu(self.conv3(x))
        x = self.pool3(x)

        x = x.reshape(x.size(0), -1) # x.size(0) is the batch size

        x = F.relu(self.fc1(x))
        # x = self.dropout(x)

        return self.fc2(x)
```

圖 2, 原本 model 的架構

所以為了防止他繼續 overfitting，我選擇使用了 dropout 的方式，因為感覺此 model 問題不大，accuracy 也蠻高的，現在的問題只有 overfitting，所以想說就直接藉由減少他對 training data 的 fitting 程度就可以了。

我增加了兩行程式碼

```
self.dropout = nn.Dropout(0.6)
x = self.dropout(x)
```

讓 model 把部分 train 出來的 neuron 丟掉，防止他過度學習 train data 的特色，而在這裡我讓 model 把 6 成的 neuron 丟掉。

```

import torch.nn as nn
import torch.nn.functional as F

class ConvModel(nn.Module):
    def __init__(self):
        super().__init__()

        # 1 channel, and using 3x3 kernels for simplicity. 256*256
        self.conv1 = nn.Conv2d(1, 32, kernel_size=3, stride=1, padding='same')
        self.pool1 = nn.MaxPool2d(kernel_size=2, stride=2) # 128*128

        self.conv2 = nn.Conv2d(32, 32, kernel_size=3, stride=1, padding='same') # 128*128
        self.pool2 = nn.MaxPool2d(kernel_size=2, stride=2) # 64*64

        self.conv3 = nn.Conv2d(32, 32, kernel_size=3, stride=1, padding='same') # 64*64
        self.pool3 = nn.MaxPool2d(kernel_size=2, stride=2) # 32*32

        flattened_dim = 32 * 32 * 32 #channel數是32

        self.fc1 = nn.Linear(flattened_dim, 32)
        self.fc2 = nn.Linear(32, 1)
        self.dropout = nn.Dropout(0.6)
    def forward(self, x):
        x = F.relu(self.conv1(x))
        x = self.pool1(x)

        x = F.relu(self.conv2(x))
        x = self.pool2(x)

        x = F.relu(self.conv3(x))
        x = self.pool3(x)

        x = x.reshape(x.size(0), -1) # x.size(0) is the batch size

        x = F.relu(self.fc1(x))
        x = self.dropout(x)
        return self.fc2(x)

```

圖 3，使用 dropout 的 model

最終結果如下，成功解決了 overfitting 的狀況，train 和 validation 的 accuracy 已經幾乎一樣了。




圖 3，使用 drop out 的後的 accuracy 和 loss

Epoch 1/30, Train loss: 0.6093, Train acc: 85.12%, Val loss: 0.3118, Val acc: 86.75%, Best Val loss: 0.3118 Best Val acc: 86.75%
Epoch 2/30, Train loss: 0.3319, Train acc: 86.12%, Val loss: 0.1740, Val acc: 93.75%, Best Val loss: 0.1740 Best Val acc: 93.75%
Epoch 3/30, Train loss: 0.2374, Train acc: 91.81%, Val loss: 0.1493, Val acc: 95.50%, Best Val loss: 0.1493 Best Val acc: 95.50%
Epoch 4/30, Train loss: 0.1969, Train acc: 92.69%, Val loss: 0.1228, Val acc: 95.50%, Best Val loss: 0.1228 Best Val acc: 95.50%
Epoch 5/30, Train loss: 0.1728, Train acc: 93.62%, Val loss: 0.1060, Val acc: 96.00%, Best Val loss: 0.1060 Best Val acc: 96.00%
Epoch 6/30, Train loss: 0.1370, Train acc: 94.56%, Val loss: 0.1477, Val acc: 94.25%, Best Val loss: 0.1060 Best Val acc: 96.00%
Epoch 7/30, Train loss: 0.1349, Train acc: 95.44%, Val loss: 0.1275, Val acc: 96.25%, Best Val loss: 0.1060 Best Val acc: 96.25%
Epoch 8/30, Train loss: 0.1358, Train acc: 95.12%, Val loss: 0.1044, Val acc: 96.00%, Best Val loss: 0.1044 Best Val acc: 96.25%
Epoch 9/30, Train loss: 0.1319, Train acc: 95.25%, Val loss: 0.1055, Val acc: 96.25%, Best Val loss: 0.1044 Best Val acc: 96.25%
Epoch 10/30, Train loss: 0.1141, Train acc: 95.50%, Val loss: 0.1383, Val acc: 96.00%, Best Val loss: 0.1044 Best Val acc: 96.25%
Epoch 11/30, Train loss: 0.1179, Train acc: 95.81%, Val loss: 0.0944, Val acc: 96.75%, Best Val loss: 0.0944 Best Val acc: 96.75%
Epoch 12/30, Train loss: 0.0915, Train acc: 96.38%, Val loss: 0.0997, Val acc: 97.00%, Best Val loss: 0.0944 Best Val acc: 97.00%
Epoch 13/30, Train loss: 0.0809, Train acc: 96.69%, Val loss: 0.1086, Val acc: 96.75%, Best Val loss: 0.0944 Best Val acc: 97.00%
Epoch 14/30, Train loss: 0.0801, Train acc: 97.38%, Val loss: 0.1043, Val acc: 96.75%, Best Val loss: 0.0944 Best Val acc: 97.00%
Epoch 15/30, Train loss: 0.0853, Train acc: 96.75%, Val loss: 0.1036, Val acc: 97.00%, Best Val loss: 0.0944 Best Val acc: 97.00%
Epoch 16/30, Train loss: 0.0771, Train acc: 97.00%, Val loss: 0.1097, Val acc: 97.00%, Best Val loss: 0.0944 Best Val acc: 97.00%
Epoch 17/30, Train loss: 0.0656, Train acc: 97.69%, Val loss: 0.1080, Val acc: 96.75%, Best Val loss: 0.0944 Best Val acc: 97.00%
Epoch 18/30, Train loss: 0.0626, Train acc: 97.31%, Val loss: 0.1090, Val acc: 96.75%, Best Val loss: 0.0944 Best Val acc: 97.00%
Epoch 19/30, Train loss: 0.0657, Train acc: 97.31%, Val loss: 0.1088, Val acc: 96.75%, Best Val loss: 0.0944 Best Val acc: 97.00%
Epoch 20/30, Train loss: 0.0671, Train acc: 97.50%, Val loss: 0.1132, Val acc: 97.00%, Best Val loss: 0.0944 Best Val acc: 97.00%
Epoch 21/30, Train loss: 0.0729, Train acc: 97.00%, Val loss: 0.1130, Val acc: 97.25%, Best Val loss: 0.0944 Best Val acc: 97.25%
Epoch 22/30, Train loss: 0.0629, Train acc: 97.81%, Val loss: 0.1136, Val acc: 97.25%, Best Val loss: 0.0944 Best Val acc: 97.25%
Epoch 23/30, Train loss: 0.0618, Train acc: 97.56%, Val loss: 0.1139, Val acc: 96.75%, Best Val loss: 0.0944 Best Val acc: 97.25%
Epoch 24/30, Train loss: 0.0715, Train acc: 96.94%, Val loss: 0.1129, Val acc: 96.75%, Best Val loss: 0.0944 Best Val acc: 97.25%
Epoch 25/30, Train loss: 0.0650, Train acc: 96.75%, Val loss: 0.1140, Val acc: 96.75%, Best Val loss: 0.0944 Best Val acc: 97.25%
Epoch 26/30, Train loss: 0.0745, Train acc: 97.00%, Val loss: 0.1136, Val acc: 96.75%, Best Val loss: 0.0944 Best Val acc: 97.25%
Epoch 27/30, Train loss: 0.0606, Train acc: 98.00%, Val loss: 0.1140, Val acc: 96.75%, Best Val loss: 0.0944 Best Val acc: 97.25%
Epoch 28/30, Train loss: 0.0721, Train acc: 97.12%, Val loss: 0.1144, Val acc: 96.75%, Best Val loss: 0.0944 Best Val acc: 97.25%
Epoch 29/30, Train loss: 0.0645, Train acc: 97.12%, Val loss: 0.1149, Val acc: 96.75%, Best Val loss: 0.0944 Best Val acc: 97.25%
Epoch 30/30, Train loss: 0.0642, Train acc: 97.50%, Val loss: 0.1150, Val acc: 97.00%, Best Val loss: 0.0944 Best Val acc: 97.25%

圖 4，更細節的測試結果

● Discussion

總而言之在我使用了 Dropout 把一些 neuron 丟掉後，出現了以下的情況

1. **Accuracy:** 實施 Dropout 後，我 train 和 validation 的 accuracy 變得幾乎相同了，也就代表這次比較沒有出現 overfitting 的現象。
2. **Loss:** 在 loss 的部分反而沒有那麼明顯，雖然似乎 loss 有比原本還低一點，但實際上 loss 也一樣很快就沒辦法繼續下降了。可能 dropout 沒辦法用來降低 loss 吧。
3. **Generalization:** 從 accuracy 來看的話，理論上此 model 變得更 generalization，因為我把 model 改成這樣後，train 和 validation 的 accuracy 基本上是很接近一模一樣

的，都約 97%左右，換句話說如果用來 test 其他 data 的話因為比較不會 overfitting，所以拿還 test 理論上會有較好的表現。

➤ Task B: Performance Comparison between CNN and ANN

Discussion

我分別使用了 `class LinearModel` and `class ConvModel`

最終 CNN 和 ANN 的差別如下

	feature extraction capabilities	training speed	model performance
CNN	較好(accuracy 較高)	2.35s/it	非常好
ANN	較差(accuracy 較低)	2.65s/it	不太好

1. feature extraction capabilities：

從結果中可以看出，CNN 的 accuracy 最終到了 97.25%，loss 則下降到 0.1052。這代表 CNN feature extraction capabilities 很好。

相比之下，ANN 模型的性能不如 CNN。ANN 的 accuracy 最終到了 94.50%，loss 則最終下降到 0.1694。雖然 ANN 也在一定程度上提高了性能，但它的性能仍然不及 CNN。代表 ANN 在圖像分類任務中的 feature extraction capabilities 不如 CNN。

此外本來 CNN model 的架構本來就是藉由提取 feature 進行簡化與優化的，所以 feature extraction capabilities 一定是 CNN 比較好。

2. training speed：

CNN 在每個周期中需要大約 2.35 秒，而 ANN 在每個周期中需要大約 2.73 秒。這代表出 CNN 在訓練速度上略微快於 ANN。這是因為 CNN 的卷積操作可以進行高效的並行計算，而 ANN 的全連接層需要更多的計算資源。

3. model performance：

根據最終的 accuracy 和 loss，可以看出 CNN 模型不管在 training 速度還是準確度和 loss 上都比 ANN 模型還強。此外從圖 6 和圖 8 的表較中可以看出，甚至在 ANN 中還有點出現 overfitting 的現象故 CNN 的表現比 ANN 好非常多。




圖 5, CNN 花的時間、loss、accuracy 等等細項




圖 6, CNN 的 accuracy 和 loss

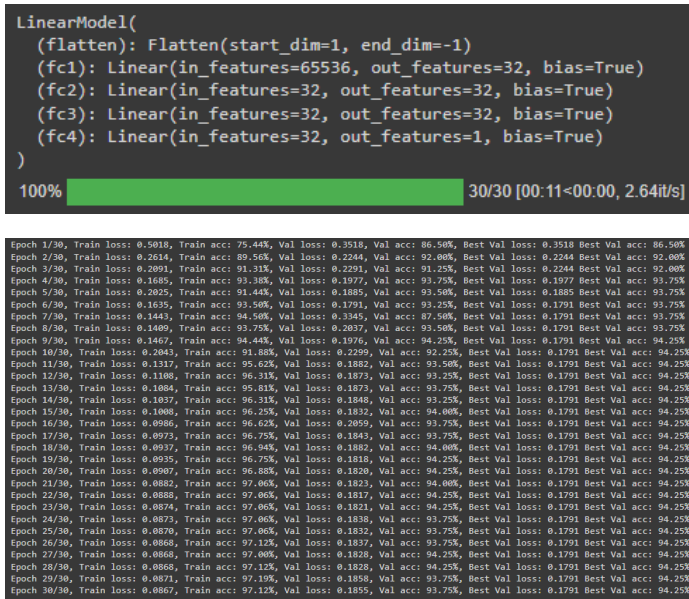


圖 7, ANN 花的時間、loss、accuracy 等等細項





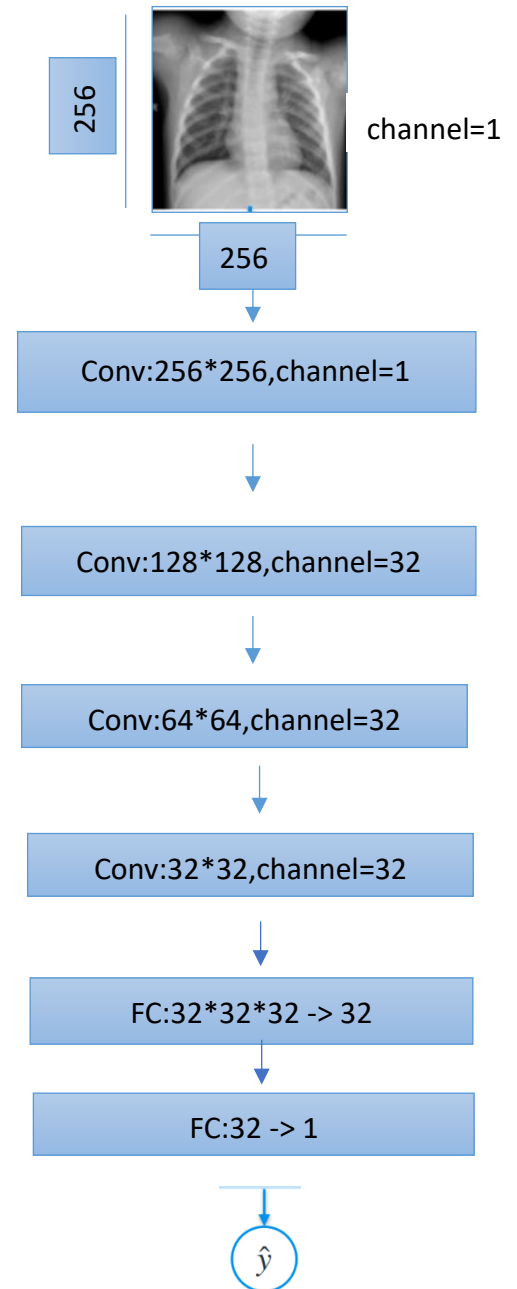
圖 8, ANN 的 accuracy 和 loss

Architecture Description

ANN



CNN



Task C: Global Average Pooling in CNNs

➤ Explanation:




圖 9, GAP 示意圖, 每個 channel 取平均

Global Average Pooling (GAP) 是一種在卷積神經網絡 (CNN) 中用於特徵提取的技術。它的主要優勢在於它可以自動消除對輸入特徵數目的需求，而不需要手動確定特徵數目。

GAP 的運作方式如下：

在 CNN 的最後一個卷積層時，GAP 會對每個 channel 的特徵圖進行平均化，讓每個通道的特徵都被壓縮成一個單一的數值。最終這些平均值的集合形成了一個特徵向量的輸出，該向量的每個元素對應於一個特徵通道。

這樣，GAP 產生了一個固定大小的特徵向量，該向量的大小獨立於輸入圖像的大小。因此最終並不需要使用到 flatten。直接輸出給 fully connected layer 即可。

➤ Increase Performance:




圖 10, 上圖為改 model 前的表現情況，accuracy 卡在 88-89%之間就上不去了所以我更改了 layer 的層數，在 model 中多增加了兩層的 layer 如下圖

```
class ConvNet(nn.Module):
    def __init__(self):
        super().__init__()
        self.net = nn.Sequential(
            nn.Conv2d(1, 32, kernel_size=3, stride=1, padding='same'),
            nn.ReLU(),
            nn.MaxPool2d(kernel_size=2, stride=2), # 128x128
            nn.Conv2d(32, 32, kernel_size=3, stride=1, padding='same'), # 128x128
            nn.ReLU(),
            nn.MaxPool2d(kernel_size=2, stride=2), # 64x64
            nn.Conv2d(32, 32, kernel_size=3, stride=1, padding='same'), # 64x64
            nn.ReLU(),
            nn.Conv2d(32, 32, kernel_size=3, stride=1, padding='same'), # 64x64
            nn.ReLU(),
            nn.Conv2d(32, 32, kernel_size=3, stride=1, padding='same'), # 64x64
            nn.ReLU(),
            nn.MaxPool2d(kernel_size=2, stride=2), # 32x32
            nn.AdaptiveAvgPool2d(1),
            nn.Flatten(),
            nn.Linear(32, 1)
        )
```

圖 11,更改後的 model




圖 12, train 和 validation 的 accuracy 都上升到了 93%左右。